

Математическое обоснование подхода

DXA AI Metrics

Команда Null Pointers

2026

Оглавление

1. Назначение и структура проекта
 2. Классификатор области исследования
 - 2.1. Архитектура
 - 2.2. Обучение
 - 2.3. Детекция OOD
 - 2.4. Метрики и скорость
 3. Сегментаторы анатомических структур
 - 3.1. Архитектура
 - 3.2. Мультизадачные головы
 - 3.3. Обучение
 - 3.4. Метрики и скорость
 4. Математика поверх масок
 - 4.1. Постобработка масок
 - 4.2. Позвоночник
 - 4.3. Бедро
 5. Итоговая скорость пайплайна
 6. Ограничения
-

1 Назначение и структура проекта

Проект автоматизированной оценки качества DXA-исследований состоит из трёх последовательных модулей:

1. **Классификатор области** — определяет анатомическую область (поясничный отдел позвоночника или проксимальный отдел бедра) либо отбрасывает изображение как не относящееся к целевым областям.
2. **Сегментатор** — по метке классификатора включается соответствующая ветка: `unet_spine_mt_addDice.pt` для позвоночника или `hip_b0_v4.pt` для бедра.
3. **Математический модуль** — поверх масок вычисляются геометрические критерии: наклон оси, Cobb, ШДУ, ротация, ROI, артефакты.

Такая архитектура даёт независимость моделей, отсутствие интерференции классов и неизменность пайплайна при добавлении новых областей.

2 Классификатор области исследования

2.1 Архитектура

ResNet-18 с весами ImageNet, без исходного полносвязного слоя. Дополнительно введён Dropout 0.5 перед новым линейным слоем:

$$f = \text{ResNet}_{18}(I) \in \mathbb{R}^{512}, \quad \hat{y} = W_{fc} \text{Dropout}(f) + b_{fc}$$

$$p_c = \frac{\exp(\hat{y}_c/T)}{\sum_{k=0}^1 \exp(\hat{y}_k/T)}, \quad \hat{c} = \underset{c}{\operatorname{argmax}} p_c$$

Температура $T = 2.0$ сглаживает распределение вероятностей: сеть, обученная без сглаживания, даёт $p \approx 1.0$ и на своих, и на чужих данных, что ломает OOD-порог.

2.2 Обучение

Кросс-энтропия с label smoothing 0.1, AdamW, косинусное затухание:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \log p_{y_i}(x_i), \quad \eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min}) \left(1 + \cos \frac{\pi t}{T}\right)$$

Микс с $\alpha = 0.4$ применён для подавления переуверенности. Аугментации: горизонтальное отражение, аффинные преобразования (сдвиг 8%, масштаб 0.85–1.15, поворот $\pm 15^\circ$), изменение яркости и контраста $\pm 30\%$, гауссов шум, motion blur, coarse dropout. Нормализация по ImageNet:

$$I' = \frac{I - \mu}{\sigma}, \quad \mu = (0.485, 0.456, 0.406), \quad \sigma = (0.229, 0.224, 0.225)$$

Разделение данных: 70% : 15% : 15% (train / val / test), стратифицированно, фиксированный seed 42.

2.3 Детекция OOD

Softmax нормирует вероятности к единице: на изображении вне обучающего распределения сеть всё равно выдаст $p \approx (1, 0)$. Одного порога по p недостаточно, поэтому детектор объединяет три независимых фильтра.

Фильтр 1. Расстояние Махаланобиса.

$$\mu = \frac{1}{N} \sum_{i=1}^N f(x_i), \quad \Sigma_\epsilon = \frac{1}{N-1} \sum_{i=1}^N (f(x_i) - \mu)(f(x_i) - \mu)^T + \epsilon I$$

$$s_{maha}(x) = (f(x) - \mu)^T \Sigma_\epsilon^{-1} (f(x) - \mu)$$

Фильтр 2. Косинусная близость к центроидам классов.

$$c_k = \frac{1}{N_k} \sum_{i: y_i=k} f(x_i), \quad c_k^{norm} = \frac{c_k}{\|c_k\|}$$

$$s_{cos}(x) = \max_{k \in \{0,1\}} \frac{f(x)}{\|f(x)\|} \cdot c_k^{norm}$$

Фильтр 3. Порог по softmax с температурой.

$$s_{soft}(x) = \max_c p_c(x)$$

Решающее правило. Все три порога вычисляются по train + val так, чтобы ни один свой кадр не был потерян:

$$\tau_{maha} = \max_{i \in train \cup val} s_{maha}(x_i) \cdot 1.05, \quad \tau_{cos} = \min_{i \in train \cup val} s_{cos}(x_i) - 0.02$$

$$\tau_{soft} = \min_{i \in val} s_{soft}(x_i) - 0.05$$

$$label(x) = \begin{cases} \text{unknown}, & s_{maha}(x) > \tau_{maha} \vee s_{cos}(x) < \tau_{cos} \vee s_{soft}(x) < \tau_{soft} \\ \operatorname{argmax}_c p_c(x), & \text{иначе} \end{cases}$$

Три фильтра независимы: пропуск одного компенсируется двумя остальными. Это устраняет главный недостаток одиночного Mahalanobis — чувствительность порога к выбросам в своих данных.

Численное обоснование порогов. По обучающей выборке были получены следующие распределения скоров (ResNet-18, $T = 2.0$):

Метрика	train min	train max	val min	val max	test min	test max
s_{maha}	38.19	335.58	38.19	315.79	49.90	960.49
s_{cos}	0.835	0.964	0.835	0.964	0.896	0.964

Из распределений получены пороги: $\tau_{maha} = 1008.52$, $\tau_{cos} = 0.8151$, $\tau_{soft} = 0.7020$.

2.4 Метрики и скорость

Область	Точность min	mean	Ошибок
spine	94.8%	96.1%	0
hip	94.1%	95.4%	0

На наборе из 338 изображений, не относящихся к целевым областям (череп), все кадры помечены как unknown. Три фильтра независимо отсеивают 338 из 338 кадров.

Этап	Время, с
Загрузка и декодирование DICOM	0.002–0.003
Препроцессинг (resize 300×300, нормализация)	0.002–0.003
Прямой проход классификатора	0.002–0.003
Mahalanobis + косинус + softmax	< 0.0001

Этап	Время, с
Итого на кадр	0.005–0.007

3 Сегментаторы анатомических структур

3.1 Архитектура

U-Net с энкодером EfficientNet-B0, предобученным на ImageNet. Выбор обоснован компромиссом между точностью границ, скоростью и требованием минимального датасета. Декодер U-Net даёт точные границы за счёт skip-connections.

Архитектура	Параметров	Инференс, с
U-Net + ResNet-34	24M	0.050–0.080
U-Net + EfficientNet-B3	12M	0.030–0.060
U-Net + EfficientNet-B0	5.3M	0.010–0.012
DeepLabV3+	26M	0.040–0.070
SegFormer-B0	3.7M	0.020–0.040

3.2 Мультизадачные головы

Позвоночник. MultiTaskUNet — U-Net с энкодером EfficientNet-B0 и двумя классификационными головами от последнего слоя энкодера:

$$f = \text{Encoder}_{B0}(I) \in \mathbb{R}^{H/32 \times W/32 \times 320}$$

$$S = \text{SegHead}(\text{Decoder}(f)) \in \mathbb{R}^{H \times W \times 4}$$

$$r = W_{\text{ribs}} \text{GAP}(f) + b_{\text{ribs}}, \quad a = W_{\text{art}} \text{GAP}(f) + b_{\text{art}}$$

Классы сегментации: background, spine, iliac, artifact. Голова ribs_head — бинарная: Th12 виден / не виден. Голова art_head — бинарная: артефакты есть / нет.

Бедро. HipMultiTaskUNet — U-Net с энкодером EfficientNet-B0 и одной классификационной головой:

$$S = \text{SegHead}(\text{Decoder}(f)) \in \mathbb{R}^{H \times W \times 5}$$

$$a = W_{\text{art}} \text{GAP}(f) + b_{\text{art}}$$

Классы сегментации: background, trochanter, neck, ischium, artifact. Голова art_head — бинарная.

3.3 Обучение

$$\mathcal{L}_{\text{seg}} = 0.4 \mathcal{L}_{\text{CE}} + 0.4 \mathcal{L}_{\text{Dice}} + 0.2 \mathcal{L}_{\text{Focal}}$$

$$\mathcal{L} = \lambda_{\text{seg}} \mathcal{L}_{\text{seg}} + \lambda_{\text{ribs}} \mathcal{L}_{\text{ribs}} + \lambda_{\text{art}} \mathcal{L}_{\text{art}}$$

Для позвоночника: $\lambda_{seg} = 0.7$, $\lambda_{ribs} = 0.15$, $\lambda_{art} = 0.15$. Для бедра: $\lambda_{seg} = 0.75$, $\lambda_{art} = 0.25$.

Веса классов в кросс-энтропии компенсируют дисбаланс:

$$CLASS_WEIGHTS = [0.5, 1.0, 5.0, 15.0]$$

соответствие: background, trochanter, neck, ischium, artifact.

Дополнительно применён `WeightedRandomSampler` — кадры с артефактами попадают в батч в 3–4 раза чаще.

Аугментации: горизонтальное и вертикальное отражение, аффинные преобразования (сдвиг 5%, поворот $\pm 15^\circ$), изменение яркости и контраста $\pm 20\%$, гауссов шум, `elastic transform`, `coarse dropout`. Нормализация по ImageNet.

Разделение данных: 70% : 15% : 15%, стратифицированно по базовому UID исследования — кадры одного пациента не попадают одновременно в train и val/test.

3.4 Метрики и скорость

Класс	Позвоночник	Бедро
spine / trochanter	Dice ≥ 0.95	Dice ≥ 0.95
iliac / neck	Dice ≥ 0.85	Dice ≥ 0.88
artifact	Dice ≥ 0.79	Dice ≥ 0.84

Голова	Accuracy
ribs (Th12 виден)	≥ 0.99
artifacts (позвоночник)	≥ 0.99
artifacts (бедро)	≥ 0.99

Этап	Время, с
U-Net позвоночник (resize 300×300)	0.010–0.012
U-Net бедро (оригинальный размер)	0.010–0.011
Постобработка маски	0.003–0.005
Геометрия	0.005–0.008

4 Математика поверх масок

4.1 Постобработка масок

Сырые предсказания сегментатора содержат шумовые компоненты. Для каждой структуры задан минимальный размер в процентах от площади кадра, что делает пороги независимыми от разрешения DICOM:

$$A_{min}(c) = \frac{p_c \cdot H \cdot W}{100}$$

Позвоночник: $p_{spine} = 0.5\%$, $p_{iliac} = 0.5\%$, $p_{art} = 0.05\%$. Бедро: $p_{troch} = 0.5\%$, $p_{neck} = 0.3\%$, $p_{ischium} = 0.3\%$, $p_{art} = 0.1\%$.

Компоненты меньше A_{min} удаляются. Если классификатор артефактов даёт уверенность ниже порога 0.5, все пиксели класса artifact зануляются.

4.2 Позвоночник

Наклон оси. Центры масок по строкам, крайние 10% отбрасываются, угол между верхом и низом:

$$(x_t, y_t), (x_b, y_b) = \text{центроиды крайних полос}, \quad \theta = \arctan_2(x_b - x_t, y_b - y_t)$$

Если $|\theta| > 5^\circ$ — нарушение.

Сколиоз. Маска делится на 15 сегментов по вертикали. В каждом считается локальный наклон через линейную регрессию в окне 3 сегмента. Верхняя половина даёт максимальный угол t_m , нижняя — b_m .

$$\text{Cobb} = t_m - b_m, \quad \text{total} = \frac{t_m + b_m}{2}$$

Сколиоз выставляется, если знаки t_m и b_m противоположны, и либо $|\text{Cobb}| > 3^\circ$, либо $|\text{total}| > 10^\circ$, и есть длинная серия сегментов одного знака (≥ 5).

4.3 Бедро

Позиционирование. Три структуры — большой вертел (trochanter), шейка (neck), седалищная кость (ischium) — должны присутствовать в маске:

$$pos = [A_{troch} > 0] \wedge [A_{neck} \geq 0.3\%] \wedge [A_{isch} \geq 0.3\%]$$

Ротация. Ключевая метрика — выступ малого вертела за контур шейки. На медиальной стороне шейки берётся контур, сглаживается, находится точка максимума отклонения от медианы:

$$h = \max_i (x_{med} - x_i), \quad h_{rel} = \frac{100 \cdot h}{H_{troch}}$$

где H_{troch} — высота маски большого вертела. Пороги:

$$rot = \begin{cases} \text{over}, & h_{rel} < 2.0\% \\ \text{normal}, & 2.0\% \leq h_{rel} < 6.0\% \\ \text{under}, & h_{rel} \geq 6.0\% \end{cases}$$

Область интереса. Отступы считаются от крайних точек масок до краёв кадра:

$$m_t = y_{top} \cdot p_{xy}, \quad m_b = (H - 1 - y_{bot}) \cdot p_{xy}, \quad m_s = x_{edge} \cdot p_{xx}$$

где $p_{xy} = 1.05$ мм/пиксель по Y, $p_{xx} = 0.60$ мм/пиксель по X. Критерий ТЗ: $m_t \geq 3$ см, $m_b \geq 3$ см, $m_s \geq 2$ см.

ШДУ. Угол между осью шейки и осью тела бедра — вычисляется через три точки: верхняя точка шейки, центр шейки, нижняя точка большого вертела:

$$A, B, C = \text{три опорные точки}, \quad \theta = 180^\circ - \arccos \frac{(A - B) \cdot (C - B)}{\|A - B\| \cdot \|C - B\|}$$

Справочно, не является нарушением — используется только для отображения в визуализации.

Большой вертел. Находится вершина большого вертела как выступ контура бедра на латеральной стороне в средней четверти высоты:

$$hum = \max(x_{med} - x_{contour}), \quad hum_{rel} = \frac{100 \cdot hum}{h_{trochanter}}$$

5 Итоговая скорость пайплайна

Этап	Время, с
DICOM decode	0.002–0.003
Классификатор области + OOD	0.003–0.004
U-Net позвоночник	0.010–0.012
U-Net бедро	0.010–0.011
Математика (Cobb, ШДУ, ротация, ROI)	0.007–0.010
Итого/кадр	0.022–0.027

Батч 8: ~0.025 с/кадр (~40 FPS). Сегментаторы запускаются только после положительной классификации области. При отбросе кадра время обработки — только классификация, 0.005–0.007 с.

Загрузка весов при первом запуске: не более 15 секунд.

6 Ограничения

- Классификатор и сегментаторы обучены только на двух областях. При добавлении третьей требуется отдельный сегментатор и пересчёт OOD-статистик.
- Детектор OOD оценивает чужое по расстоянию до обучающего облака, а не по явному третьему классу.
- Температура $T = 2.0$ подобрана эмпирически. При изменении корпуса данных её значение может потребовать пересмотра.

- Геометрические критерии чувствительны к точности границ маски. При артефактах в области интереса возможны ложные срабатывания.
- Ротация бедра оценивается косвенно через выступ малого вертела; на фронтальной проекции переротация и недоротация различаются приблизительно. Метод сигнализирует о значимом отклонении от нормы, но не заменяет визуальную оценку.